



官方 DAPO · 一次更新的执行验收

原始 Qwen3.5-9B 基座 · 同一道 ATE 任务的四条独立轨迹 · 动作掩码已逐段核对


环境质量与官方长度惩罚后的奖励




对隐藏因果真值的实际误差



损失掩码保留模型动作、排除工具文本



实际标量观测开销与误差



一个训练步不足以判断收敛。上述轨迹均由更新前策略生成，不能用它们推断训练后的能力变化。
轨迹 2 返回零向量，质量为 0.955；这是本题的常数基线，不能单凭高奖励判断推理能力。