


模型与同题观察参考：得分和真实误差


前 51 次更新 · 动态过滤前全部训练采样 · 仅比较有最终答案的相同轨迹

模型 总体观察参考 观察排名第二（干预题）





平均处理效应 · ATE
有效比较 34/36 条



反事实概率区间
有效比较 39/40 条



最佳干预选择
有效比较 67/68 条



参考使用总体观察概率，不是基座模型成绩，也不是有限采样程序的实测成绩。

缺少答案的轨迹没有数值误差，未填 0；其失败计入全采样得分与完成率。各题使用同一评分函数。

强反转使观察第一名参照偏弱，故同时列第二名。训练题不断变化，这些曲线不证明泛化或学习增益。