


官方 DAPO：奖励与更新耗时


45 次真实更新 · 180 条保留轨迹 · 52 个生成题组（含过滤组）

—●— 平均处理效应 · ATE —●— 后门调整集 —●— 中介变量集合
—●— 个体反事实概率 —●— 最佳干预选择 - - - 训练奖励均值（含长度惩罚）

终止质量：浅色为单条轨迹，实点为同题组均值



训练步耗时（验证另计）：题目、轨迹长度及补采样次数均会改变工作量



虚线：第 6 步起启用编译；第 16 步起使用已验收的进度补丁。

各步使用不同训练题。这是采样时表现，不能据此证明更新后的能力提高。