


官方 DAPO：奖励与更新耗时


51 次真实更新 · 204 条保留轨迹 · 59 个生成题组（含过滤组）

平均处理效应 · ATE 后门调整集 中介变量集合
个体反事实概率 最佳干预选择 训练奖励均值（含长度惩罚）

最终答案得分（未扣超长惩罚）：浅色为单条轨迹，实点为同题组均值



训练步耗时（验证另计）：题目、轨迹长度及补采样次数均会改变工作量



第 50 步原生更新已保存；取消验证时尚未打印最终日志，相关曲线留空。

各步使用不同训练题。这是采样时表现，不能据此证明更新后的能力提高。